# Ψηφιακή Επεξεργασία Εικόνας - 3η εργασία

Κουδούνης Βασίλειος

AEM:10739

## Επεξήγηση συναρτήσεων

### Συνάρτηση **image_to_graph**

Η συνάρτηση image_to_graph(img_array) μετατρέπει μια έγχρωμη εικόνα διαστάσεων $(M, N, C)$ σε έναν πλήρως συνδεδεμένο μη-κατευθυντικό γράφο με $MN$ κόμβους, όπου κάθε κόμβος αντιστοιχεί σε ένα πιξελ της εικόνας.

Βήματα υλοποίησης:

1. Αναδιάταξη εικόνας: Η εικόνα μετατρέπεται σε πίνακα σχήματος $[MN, C]$, όπου κάθε γραμμή περιέχει τα χρωματικά χαρακτηριστικά ενός πιξελ στο χώρο των καναλιών (π.χ. RGB).
2. Υπολογισμός αποστάσεων: Υπολογίζεται ο πίνακας ευκλείδειων αποστάσεων $d(i, j)$ μεταξύ όλων των ζευγών pixels στο χώρο $\mathbb{R}^C$:
$$d(i, j) = \|x_i - x_j\|_2$$
3. Υπολογισμός **affinity** πίνακα: Ορίζεται ο πίνακας ομοιότητας (affinity) $A \in \mathbb{R}^{MN \times MN}$ ως:
$$A(i, j) = \exp(-d(i, j))$$
Δηλαδή, η ομοιότητα μεταξύ δύο pixels μειώνεται εκθετικά όσο αυξάνεται η απόστασή τους στο χρωματικό χώρο.

Έξοδος: Η συνάρτηση επιστρέφει τον συμμετρικό πίνακα $A$, ο οποίος περιγράφει την τοπική και παγκόσμια συσχέτιση όλων των πιξελς της εικόνας. Ο πίνακας αυτός μπορεί να χρησιμοποιηθεί ως είσοδος σε μεθόδους clustering όπως spectral clustering ή normalized cuts.

### Συνάρτηση **spectral_clustering**

Η συνάρτηση spectral_clustering(affinity_mat, k) εφαρμόζει τη μέθοδο spectral clustering σε έναν πλήρως συνδεδεμένο γράφο που περιγράφεται από τον πίνακα ομοιότητας (affinity) $A$, με στόχο τον διαχωρισμό των κόμβων σε $k$ ομάδες.

Βήματα υλοποίησης:

1. Αραιή αναπαράσταση: Ο πίνακας ομοιότητας $A$ μετατρέπεται σε αραιή μορφή για αποδοτικότερους υπολογισμούς.
2. Υπολογισμός μη κανονικοποιημένου **Laplacian**: Ορίζεται ο μη κανονικοποιημένος γράφος Laplacian ως:
$$L = D - A$$
όπου $D$ είναι ο διαγώνιος πίνακας βαθμών με:
$$D(i, i) = \sum_j A(i, j)$$

3. Ιδιοδιανύσματα **Laplacian**: Υπολογίζονται τα $k$ ιδιοδιανύσματα του $L$ που αντιστοιχούν στις μικρότερες ιδιοτιμές (πλην της μηδενικής), δηλαδή τα $k$ σημαντικότερα modes ομαδοποίησης.

4. Κανονικοποίηση χαρακτηριστικών: Το πινάκιο $U$ των ιδιοδιανυσμάτων κανονικοποιείται ανά γραμμή ώστε κάθε κόμβος να εκπροσωπείται από μοναδιαίο διάνυσμα:

$$U_{\text{νορμ}}[i] = \frac{U[i]}{\|U[i]\|}$$

5. Ομαδοποίηση με **k-means**: Εφαρμόζεται k-means clustering στα κανονικοποιημένα διανύσματα $U_{\text{νορμ}}$ για την ανάθεση κόμβων σε clusters.

Έξοδος: Επιστρέφεται ένα διάνυσμα με τις τελικές ετικέτες (clusters) για κάθε κόμβο του γράφου. Οι ομάδες αντανακλούν την δομή του γράφου όπως αυτή αναδύεται από τις ιδιότητες του Laplacian.

## Συνάρτηση **n_cuts**

Η συνάρτηση `ν_ςυτσ(affinity_mat, k)` υλοποιεί μια μορφή spectral clustering βασισμένη στη χαλάρωση του προβλήματος Normalized Cuts (Ncut), με στόχο τον διαχωρισμό των κόμβων του γράφου σε k ομάδες.

Βήματα υλοποίησης:

1. Υπολογισμός **Laplacian** γραφήματος: Από τον πίνακα γειτνίασης (affinity matrix) $W$, υπολογίζεται ο διαγώνιος πίνακας βαθμών $D$ και ο μη κανονικοποιημένος Laplacian:

$$L = D - W$$

2. Ιδιοανάλυση του **Laplacian**: Υπολογίζονται τα k ιδιοδιανύσματα που αντιστοιχούν στις k μικρότερες ιδιοτιμές του $L$:

$$Lu_i = \lambda_i u_i, \quad i = 1, \ldots, k$$

   Τα ιδιοδιανύσματα αποτελούν γραμμικά χαρακτηριστικά του γράφου και καταγράφονται σε πίνακα $U$.

3. Κανονικοποίηση γραμμών: Οι γραμμές του πίνακα $U$ κανονικοποιούνται ώστε κάθε κόμβος να εκπροσωπείται από μοναδιαίο διάνυσμα:

$$U_{\text{νορμ}}[i] = \frac{U[i]}{\|U[i]\|}$$

   Αυτό αυξάνει τη διαχωρισιμότητα στον χώρο των ιδιοδιανυσμάτων.

4. Ομαδοποίηση με **k-means**: Εφαρμόζεται k-means clustering στα κανονικοποιημένα διανύσματα για την ανάθεση των κόμβων σε k clusters.

Έξοδος: Επιστρέφεται διάνυσμα labels που αντιστοιχούν σε κάθε κόμβο του γράφου και καθορίζουν το cluster στο οποίο ανήκει.

## Συνάρτηση **calculate_n_cut_value**

Η συνάρτηση calculate_n_cut_value(affinity_mat, cluster_idx) υπολογίζει τη μετρική Normalized Cut (Ncut) για έναν διαχωρισμό των κόμβων ενός γράφου σε δύο ομάδες.

Είσοδος:

- affinity_mat: Πίνακας ομοιότητας $W \in \mathbb{R}^{N \times N}$ που περιγράφει τον γράφο.
- cluster_idx: Διάνυσμα ετικετών που υποδεικνύει τον διαχωρισμό των κόμβων σε δύο ομάδες (0 ή 1).

Υπολογισμός:

1. Ταυτοποιούνται οι κόμβοι των δύο ομάδων:

$$A = \{i \mid \text{cluster_idx}[i] = 0\}, \quad B = \{i \mid \text{cluster_idx}[i] = 1\}$$

2. Υπολογίζεται η ενδο-συνδεσιμότητα κάθε ομάδας:

$$\text{assoc}(A, A) = \sum_{i \in A, j \in A} W(i, j), \quad \text{assoc}(B, B) = \sum_{i \in B, j \in B} W(i, j)$$

3. Υπολογίζεται η συνολική συνδεσιμότητα κάθε ομάδας προς όλο τον γράφο:

$$\text{assoc}(A, V) = \sum_{i \in A, j \in V} W(i, j), \quad \text{assoc}(B, V) = \sum_{i \in B, j \in V} W(i, j)$$

4. Υπολογίζεται η κανονικοποιημένη συσχέτιση:

$$\text{Nassoc} = \frac{\text{assoc}(A, A)}{\text{assoc}(A, V)} + \frac{\text{assoc}(B, B)}{\text{assoc}(B, V)}$$

5. Τέλος, υπολογίζεται η τιμή Ncut:

$$\text{Ncut} = 2 - \text{Nassoc}$$

Έξοδος: Επιστρέφεται η τιμή Ncut $\in [0, 2]$. Όσο μικρότερη είναι, τόσο καλύτερος θεωρείται ο διαχωρισμός μεταξύ των δύο ομάδων.

## Συνάρτηση **n_cuts_recursive**

Η συνάρτηση n_cuts_recursive(affinity_mat, T1, T2) υλοποιεί την αναδρομική έκδοση της μεθόδου Normalized Cuts, βασισμένη σε επαναλαμβανόμενες διχοτομήσεις με χρήση spectral clustering και απόφαση με βάση τη μετρική Ncut.

Είσοδος:

- affinity_mat: ο πίνακας ομοιότητας (γράφος) διαστάσεων $N \times N$
- T1: κατώφλι για το ελάχιστο επιτρεπτό μέγεθος cluster
- T2: κατώφλι για τη μέγιστη επιτρεπτή τιμή Ncut ώστε να θεωρηθεί αποδεκτός ο διαχωρισμός

Λογική υλοποίησης:

1. Αρχικοποιείται μια ουρά (queue) με όλους τους κόμβους και ένα αρχικό cluster_id.
2. Όσο υπάρχουν υποψήφια σύνολα στην ουρά:
   - Αν το μέγεθος είναι μικρότερο από T1, αποδίδεται ετικέτα χωρίς διαχωρισμό.
   - Αλλιώς εφαρμόζεται spectral clustering με $k = 2$ στο υποσύνολο.
3. Υπολογίζεται η τιμή Ncut μεταξύ των δύο ομάδων.
4. Αν η τιμή είναι μεγαλύτερη από T2, τότε δεν επιτρέπεται σπλιτ και αποδίδεται κοινή ετικέτα.
5. Αν η τιμή είναι μικρότερη ή ίση από T2, προωθούνται τα δύο νέα υποσύνολα στην ουρά για περαιτέρω έλεγχο.

Έξοδος: Επιστρέφεται πίνακας ετικετών (labels) μήκους $N$ που καθορίζει σε ποιο cluster ανήκει κάθε κόμβος. Ο αριθμός των τελικών ομάδων προκύπτει δυναμικά από τη διαδικασία.

## demo1.py

Πίνακας 1: Αποτελέσματα spectral clustering για διαφορετικές τιμές $k$ στον γράφο d1a

| Τιμή $k$ | Ετικέτες **(labels)** |
|---|---|
| 2 | [1 1 1 1 0 0 0 0 1 1 1 1] |
| 3 | [2 2 2 2 0 0 0 0 1 1 1 1] |
| 4 | [1 1 1 1 2 0 2 0 3 3 3 3] |

Ο πίνακας d1a περιγράφει έναν μικρό γράφο 12 κόμβων. Η εφαρμογή spectral clustering για διαφορετικά $k$ δείχνει ότι:

Για $k = 2$, εντοπίζεται ένας σαφής χωρισμός σε δύο κοινότητες.

Για $k = 3$, οι κόμβοι διαχωρίζονται σε τρία ισομεγέθη και διακριτά clusters.

Για $k = 4$, παρατηρείται επιπλέον εσωτερικός διαχωρισμός, πιθανόν λόγω τοπικών διαφορών στη δομή του γράφου.

Αυτό καταδεικνύει την ικανότητα της μεθόδου να προσαρμόζεται στην πολυπλοκότητα του γράφου και να αποκαλύπτει την πολυεπίπεδη ομαδοποιητική του δομή.

## demo2.py

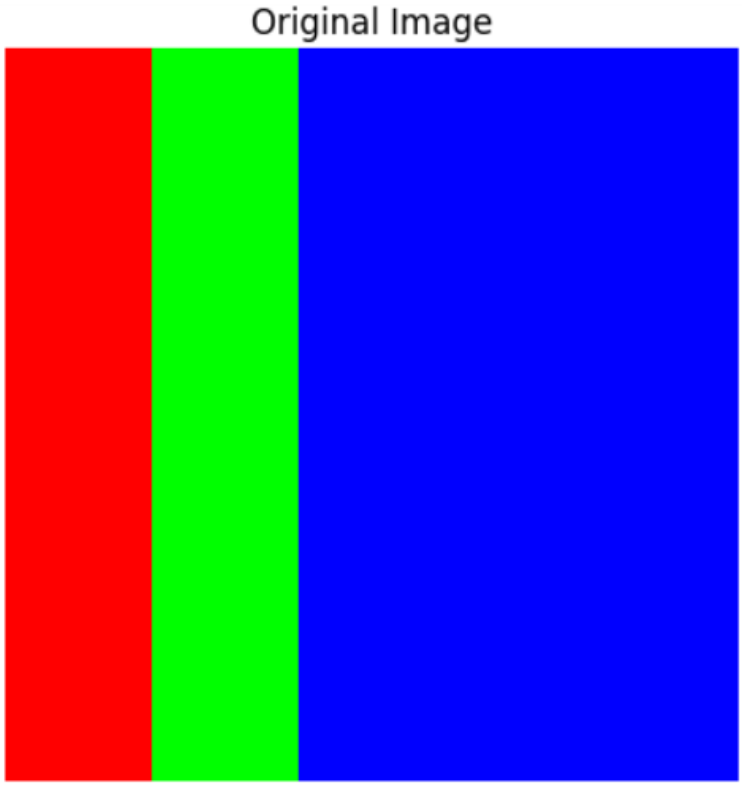

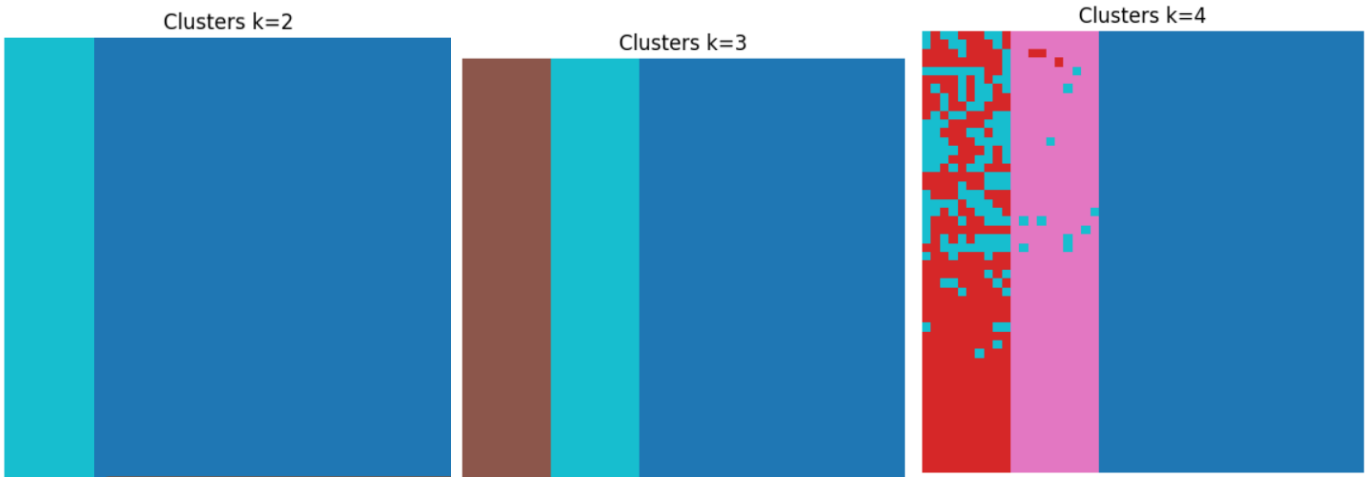


Στο πλαίσιο του Demo 2, εφαρμόστηκε η μέθοδος Spectral Clustering σε μια τεχνητή εικόνα που αποτελείται από τρεις καθαρές κάθετες ζώνες χρώματος (κόκκινη, πράσινη, μπλε). Η συμπεριφορά του αλγορίθμου αναλύθηκε για διαφορετικές τιμές του αριθμού ομάδων $k$:

- Για $k = 2$: ο αλγόριθμος διαχωρίζει επιτυχώς το μπλε τμήμα από τα υπόλοιπα (κόκκινο και πράσινο), τα οποία συγχωνεύει σε μία κοινή ομάδα. Αυτό υποδηλώνει ότι η απόσταση των χαρακτηριστικών μεταξύ κόκκινου και πράσινου είναι μικρότερη από τη διαφορά με το μπλε, γεγονός που οδηγεί στην ένωση των δύο πρώτων.
- Για $k = 3$: τα αποτελέσματα είναι άριστα. Η κάθε χρωματική περιοχή (κόκκινο, πράσινο, μπλε) αναγνωρίζεται και ταξινομείται σε ξεχωριστό clustερ. Η τεχνική spectral clustering επιτυγχάνει πλήρη αντιστοίχιση με την υποκείμενη δομή της εικόνας.
- Για $k = 4$: παρατηρείται υπερκατάτμηση, κυρίως στις περιοχές του κόκκινου και του πράσινου τμήματος. Ο αλγόριθμος αναγκάζεται να δημιουργήσει επιπλέον ομάδες, οι οποίες δεν έχουν οπτική ή σημασιολογική βάση. Το αποτέλεσμα είναι ασυνεπές και περιλαμβάνει θόρυβο.

Γενική Παρατήρηση: Η μέθοδος spectral clustering αποδίδει πολύ καλά όταν ο αριθμός των ομάδων $k$ είναι ευθυγραμμισμένος με τη φυσική δομή των δεδομένων. Όταν ο $k$ είναι μικρότερος ή μεγαλύτερος από τον πραγματικό αριθμό διακριτών περιοχών, το αποτέλεσμα είτε συγχωνεύει ομάδες, είτε τις τεμαχίζει υπερβολικά.

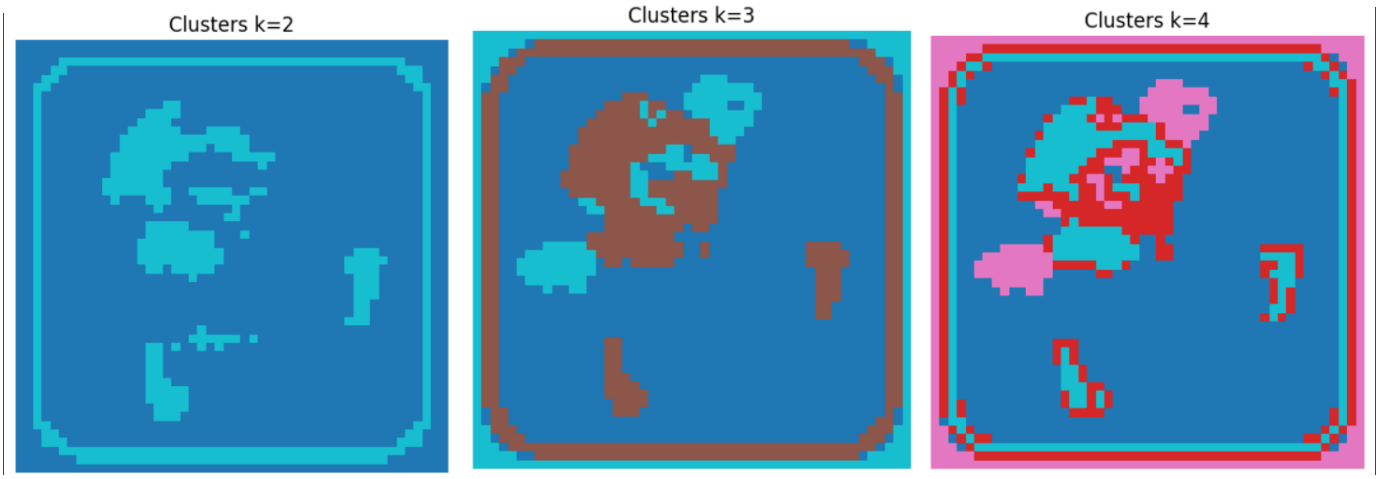


Η δεύτερη εικόνα περιλαμβάνει πολύπλοκο και φυσικό περιεχόμενο, καθώς απεικονίζει έναν χαρακτήρα κινουμένων σχεδίων με μεγάλη ποικιλία χρωμάτων, φωτεινοτήτων και υφών. Η μέθοδος spectral clustering εφαρμόστηκε με τιμές $k = 2, 3, 4$, και τα αποτελέσματα αξιολογούνται ως εξής:

- $k = 2$: Η εικόνα διαχωρίζεται σε δύο βασικές περιοχές. Ο χαρακτήρας (κυρίως το σώμα του Μαριο) εντοπίζεται ως διακριτή ομάδα έναντι του υπόβαθρου. Αν και δεν επιτυγχάνεται πλήρης οπτική απομόνωση των άκρων ή λεπτομερειών, η βασική διαίρεση έχει ουσιαστικό νόημα.
- $k = 3$: Παρατηρείται καλύτερος διαχωρισμός επιμέρους στοιχείων του χαρακτήρα. Η κόκκινη στολή, τα μπλε ρούχα και το υπόβαθρο εντοπίζονται ως ξεχωριστά clusters. Το αποτέλεσμα είναι πιο εκφραστικό και πλησιάζει περισσότερο τη δομή της εικόνας.
- $k = 4$: Η μέθοδος εισάγει περισσότερα clusters, προσπαθώντας να απομονώσει επιμέρους περιοχές όπως πρόσωπο, γάντια ή σκιάσεις. Ωστόσο, το αποτέλεσμα εμφανίζει θόρυβο – ιδίως στην περιοχή του φόντου

και των άκρων – γεγονός που δηλώνει υπερκατάτμηση. Δηλαδή, ενώ κάποιες λεπτομέρειες αναδεικνύονται, η συνοχή των περιοχών υποβαθμίζεται.

Γενική Παρατήρηση: Η μέθοδος spectral clustering εφαρμόζεται με επιτυχία και σε εικόνες υψηλής πολυπλοκότητας, αναδεικνύοντας σημαντικές χρωματικές δομές. Παρόλα αυτά, η επιλογή του αριθμού ομάδων $k$ επηρεάζει δραστικά την ποιότητα της κατάτμησης: μικρές τιμές οδηγούν σε υπεραπλουστευμένα αποτελέσματα, ενώ μεγάλες τιμές προκαλούν θόρυβο και υπερκατάτμηση χωρίς πρακτικό όφελος.

## demo3a.py

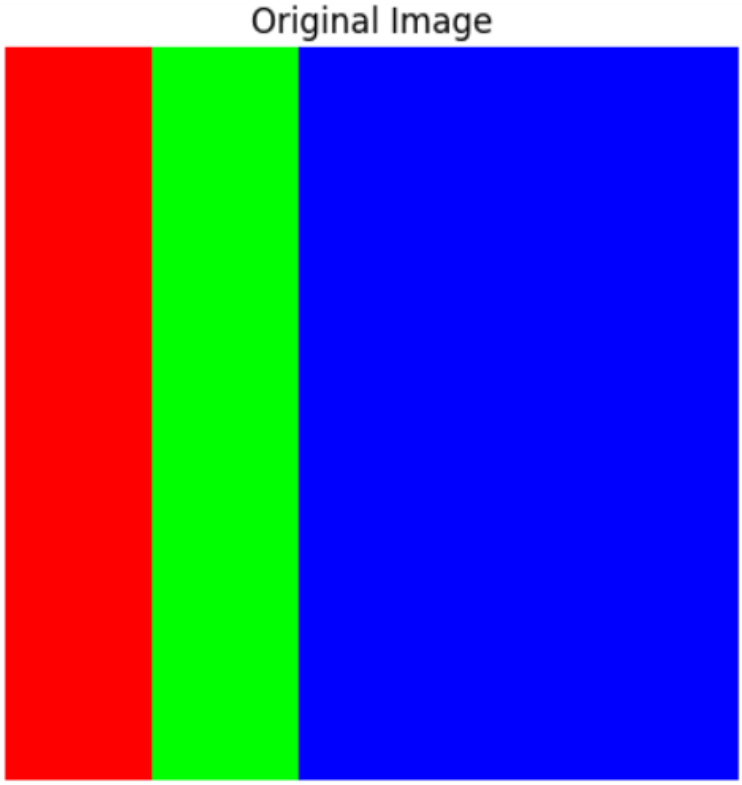


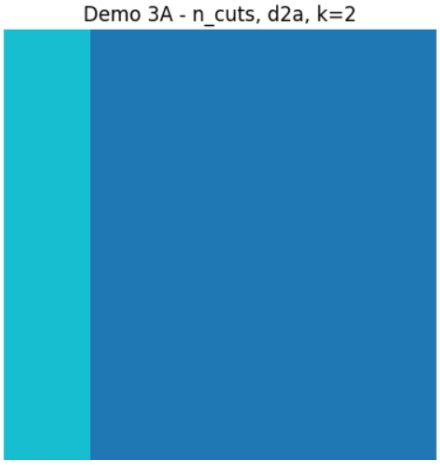


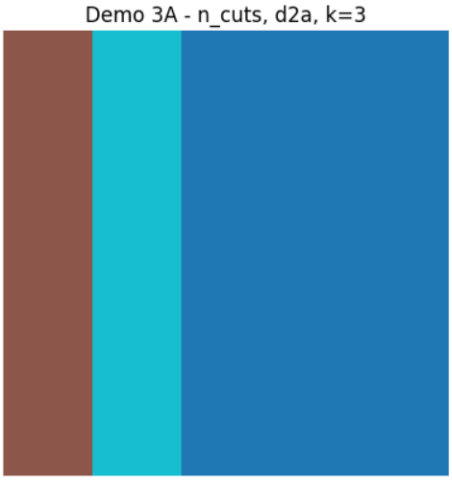


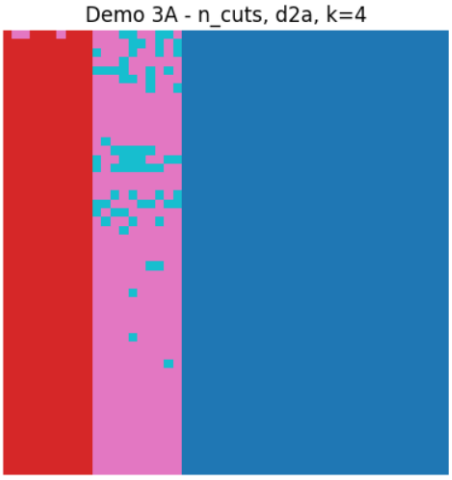

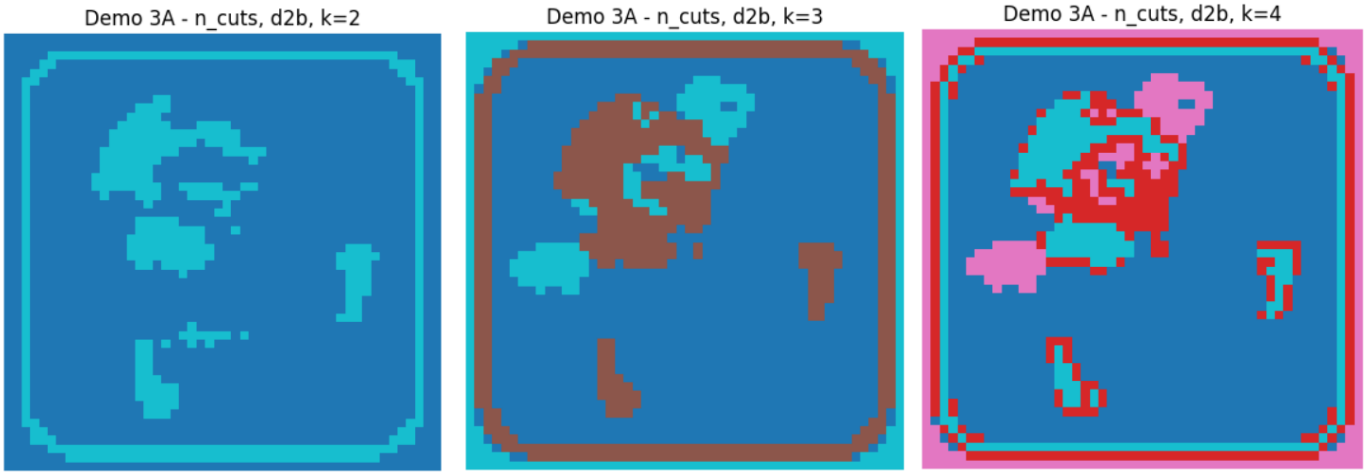


Για κάθε μία από τις δύο εικόνες εισόδου (δ2α και δ2β), εφαρμόστηκε η μη-αναδρομική εκδοχή της μεθόδου n-cuts, για τιμές αριθμού ομάδων $k = 2, 3, 4$. Ακολουθούν τα κυριότερα συμπεράσματα από την οπτική αξιολόγηση των αποτελεσμάτων:

Εικόνα Α (απλή συνθετική εικόνα με χρωματικές περιοχές):

- Για $k = 2$, παρατηρείται ο διαχωρισμός της αριστερής περιοχής (κόκκινο και πράσινο) από τη δεξιά (μπλε). Αν και δεν αντιστοιχεί ακριβώς στις αρχικές 3 χρωματικές περιοχές, το αποτέλεσμα είναι λογικό με βάση τη χρωματική ομοιότητα κόκκινου-πράσινου ως προς το μπλε.

- Για $k = 3$, η μέθοδος επιτυγχάνει σχεδόν τέλειο διαχωρισμό των τριών κατακόρυφων περιοχών χρώματος, αποτυπώνοντας σωστά την δομή της εικόνας.
- Για $k = 4$, εμφανίζονται κάποιες τοπικές διασπάσεις κυρίως στις κόκκινες και πράσινες περιοχές, πιθανώς λόγω μικρών αριθμητικών διαφορών ή θορύβου. Ωστόσο, ο πυρήνας των 3 αρχικών περιοχών παραμένει ορατός.

Εικόνα B (εικόνα πραγματικού κόσμου - **Mario**):

- Για $k = 2$, η μέθοδος ξεχωρίζει το σώμα/φιγούρα του Mario από το φόντο, κάτι που είναι απολύτως επιθυμητό.
- Για $k = 3$, παρατηρείται ένας πιο λεπτομερής διαχωρισμός με εμφάνιση ανεξάρτητων περιοχών για καπέλο/ρούχα, πρόσωπο και φόντο, που δείχνει την ικανότητα της μεθόδου να εντοπίζει πιο σύνθετες περιοχές.
- Για $k = 4$, ο διαχωρισμός συνεχίζεται σε πιο μικρές υποπεριοχές (π.χ. σκιά στο φόντο, ξεχωριστά σημεία ρούχων), όμως εμφανίζεται και μικρός θόρυβος (μερικά διάσπαρτα πιξελς), πιθανώς λόγω υπερκατακερματισμού.

Συμπεράσματα: Η μη-αναδρομική μέθοδος n-cuts αποδίδει ικανοποιητικά για μικρές τιμές $k$, ιδιαίτερα όταν η εικόνα έχει καθαρές, διαχωρίσιμες περιοχές. Σε πιο σύνθετες εικόνες, η επιλογή $k$ επηρεάζει σημαντικά την ποιότητα της ομαδοποίησης. Η μέθοδος καταφέρνει να αποδώσει τη γενική δομή του περιεχομένου, αλλά με υψηλότερες τιμές $k$ είναι πιθανό να προκύψει υπερκατακερματισμός.

## demo3b.py

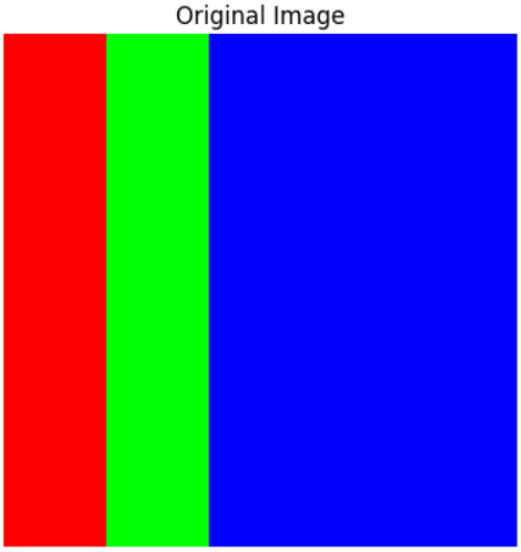

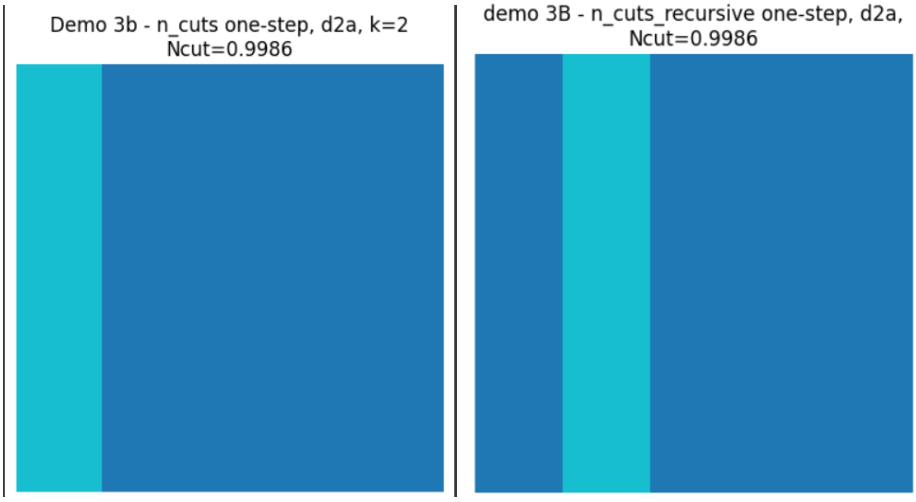


Αποτελέσματα **Demo 3b** (εικόνα **d2b**)

Στο πλαίσιο του Demo 3b, εφαρμόστηκε η μέθοδος n_cuts για ένα βήμα διαχωρισμού πάνω στην εικόνα d2b, δηλαδή το γράφημα χωρίστηκε σε δύο υποσύνολα ($k = 2$). Παράλληλα, εφαρμόστηκε η ίδια διαδικασία και μέσω της n_cuts_recursive με προκαθορισμένο $k = 2$.

Παρατηρήσεις:

- Η μέθοδος n_cuts παρήγαγε καθαρό διαχωρισμό της εικόνας σε δύο περιοχές, ακολουθώντας κυρίως τη χρωματική πληροφορία.
- Η n_cuts_recursive έδωσε σχεδόν ταυτόσημα αποτελέσματα, όπως είναι αναμενόμενο για $k = 2$ και ένα βήμα.
- Η μετρική Ncut έχει την ίδια πολύ υψηλή τιμή ($\approx 0.9986$), γεγονός που υποδεικνύει ότι τα δύο clusters έχουν σχετικά ανεξάρτητη συνδεσιμότητα μεταξύ τους.

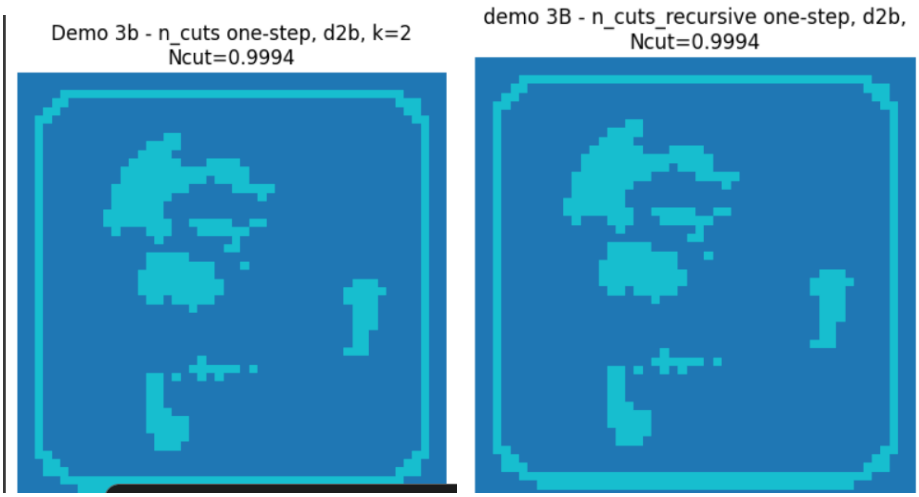


Για το Demo 3b εφαρμόστηκε η μέθοδος n_cuts και η αναδρομική n_cuts_recursive για ένα μόνο βήμα διαχωρισμού ($k = 2$) στην εικόνα d2a. Τα αποτελέσματα που προκύπτουν συνοδεύονται από την αντίστοιχη τιμή της μετρικής Ncut.

Παρατηρήσεις:

- Και στις δύο μεθόδους (n_cuts και n_cuts_recursive), η εικόνα διαχωρίζεται σε δύο βασικές περιοχές: μία μικρή ζώνη στα αριστερά και το υπόλοιπο τμήμα της εικόνας.
- Η τιμή της μετρικής Ncut είναι ίδια και στις δύο περιπτώσεις: Ncut $= 0.9986$, υποδηλώνοντας έναν πολύ «καθαρό» διαχωρισμό με μικρή συνδεσιμότητα μεταξύ των ομάδων.
- Η διαφορά μεταξύ των δύο μεθόδων εντοπίζεται στην ακριβή τοποθέτηση της τομής: η n_cuts διαχωρίζει ένα ευρύτερο τμήμα, ενώ η n_cuts_recursive εντοπίζει πιο στενά το όριο και απομονώνει κυρίως τη μεσαία ζώνη.

Σύγκριση με **Spectral Clustering**: Η διαδικασία spectral clustering με $k = 2$ (όπως χρησιμοποιήθηκε στο Demo 2) είχε επίσης εντοπίσει την ίδια περιοχή ενδιαφέροντος στην εικόνα (αριστερή λωρίδα). Επομένως:

- Οι μέθοδοι είναι συνεπείς ως προς τον εντοπισμό των σημαντικών διαχωριστικών περιοχών.
- Οι διαφοροποιήσεις αφορούν κυρίως τα όρια των περιοχών και όχι τη γενική κατεύθυνση του διαχωρισμού.

Συμπέρασμα: Η μέθοδος n_cuts (είτε αναδρομικά είτε όχι) για $k = 2$ παράγει αντίστοιχα αποτελέσματα με τη spectral clustering, ιδιαίτερα όταν η εικόνα εμφανίζει σαφή κατακόρυφα όρια μεταξύ των περιοχών. Η μετρική Ncut επιβεβαιώνει την ποιότητα του διαχωρισμού.

## demo3c.py

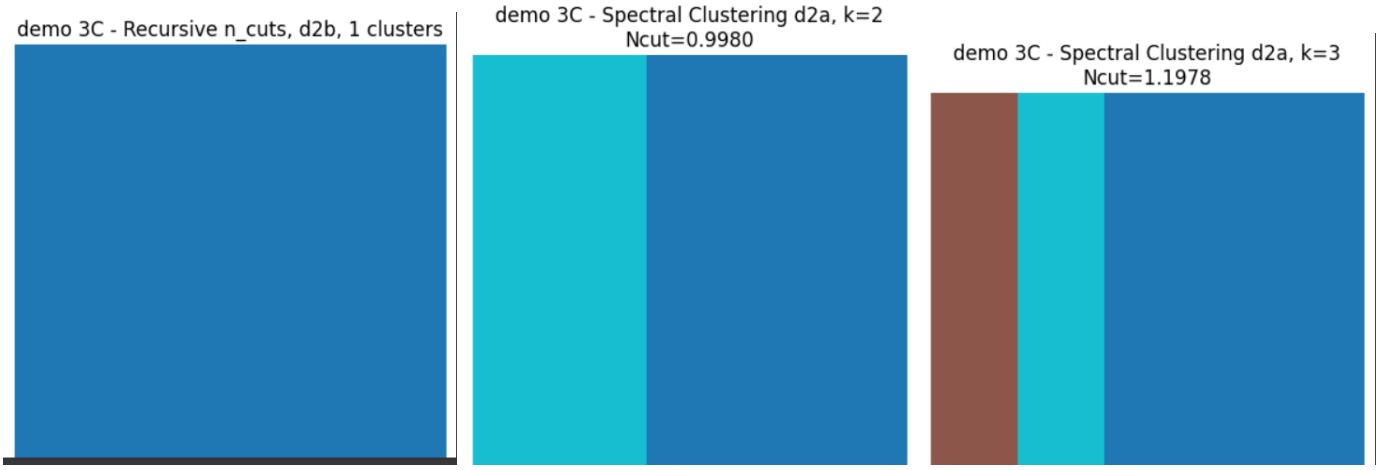


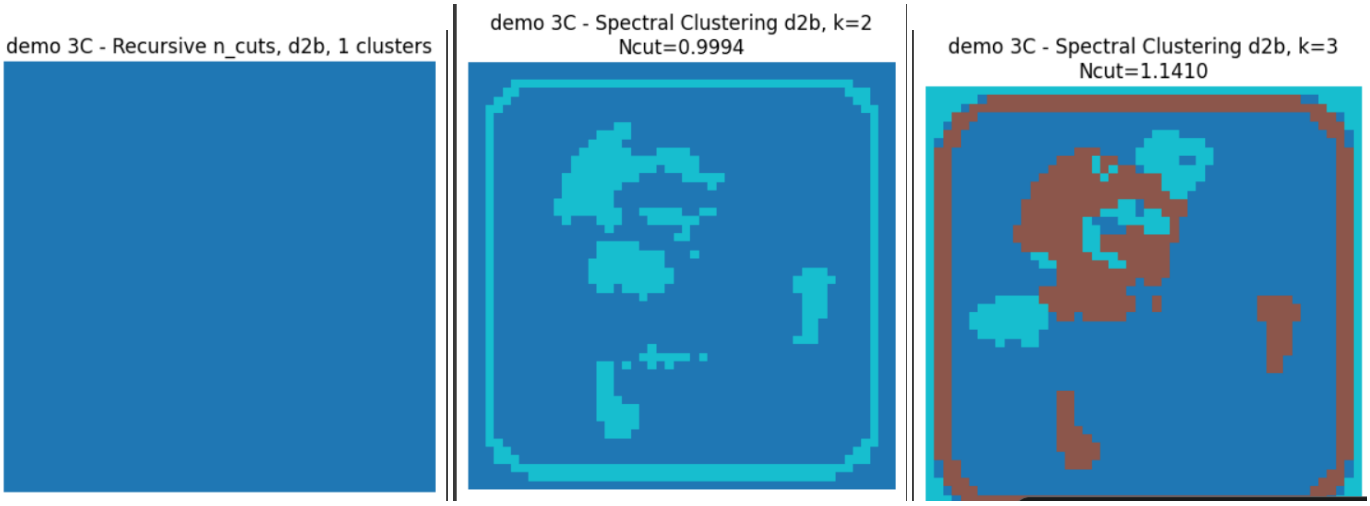


### Συμπεράσματα – **Demo 3c**

Η πλήρης (αναδρομική) εκτέλεση της μεθόδου n_cuts_recursive εφαρμόστηκε στις εικόνες d2a και d2b, με τιμές κατωφλιών T1=5 και T2=0.20. Παρατηρήθηκε ότι και στις δύο εικόνες, η συνθήκη διαχωρισμού Ncut > T2 ικανοποιήθηκε ήδη από την πρώτη απόπειρα διχοτόμησης. Συνεπώς, κανένας κόμβος δεν χωρίστηκε περαιτέρω και το τελικό αποτέλεσμα ήταν ένα ενιαίο μοναδικό **cluster**.

Αυτό δείχνει ότι με τα συγκεκριμένα κατώφλια, η μέθοδος δεν θεώρησε επωφελές να σπάσει τον γράφο και παρέμεινε συντηρητική, ακόμα και σε περιπτώσεις όπου οπτικά υπάρχουν εμφανείς περιοχές ενδιαφέροντος.

Σε σύγκριση με τη μη-αναδρομική μορφή του n_cuts για k=2,3, καθώς και με τη μέθοδο Spectral Clustering, παρατηρείται ότι:

- Η μη-αναδρομική μέθοδος n_cuts για k=3 διαχωρίζει ικανοποιητικά τις επιμέρους περιοχές στις εικόνες d2a και d2b.
- Η μέθοδος **Spectral Clustering** με k=3 δίνει επίσης λογικούς διαχωρισμούς με ευκρινείς περιοχές, ειδικά στην εικόνα d2b.

- Η αναδρομική **n_cuts** αποτυγχάνει να διακρίνει οποιαδήποτε υποδομή ή δομή λόγω των αυστηρών τιμών κατωφλίου.

Συμπερασματικά, σε αυτό το παράδειγμα η μη-αναδρομική προσέγγιση με καθορισμένο k οδηγεί σε πιο διακριτές και ουσιαστικές τμηματοποιήσεις σε σχέση με την πιο προσεκτική αναδρομική εκδοχή.

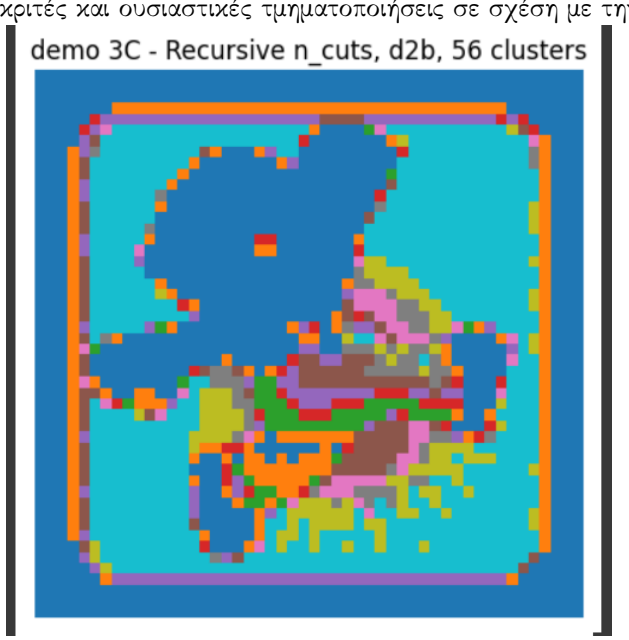


Κατά την εκτέλεση της αναδρομικής μεθόδου n_cuts_recursive με κατώφλια T1 = 500 και T2 = 2.0, παρατηρήθηκε σημαντική βελτίωση στην τμηματοποίηση της εικόνας d2b. Η μέθοδος εντόπισε λεπτομερώς διαφορετικές δομές και περιοχές ενδιαφέροντος, δημιουργώντας 56 διαφορετικά clusters, τα οποία ευθυγραμμίζονται με τα οπτικά χαρακτηριστικά της εικόνας.

Ωστόσο, στην εικόνα d2a η ίδια παραμετροποίηση δεν απέδωσε αντίστοιχα ικανοποιητικά αποτελέσματα. Το πλήθος των περιοχών που εντοπίστηκαν ήταν περιορισμένο και δεν αντιστοιχούσαν στις αναμενόμενες χρωματικές περιοχές. Το φαινόμενο αυτό μπορεί να οφείλεται στη χαμηλότερη πολυπλοκότητα και ποικιλομορφία της εικόνας d2a, καθώς και στη δυσκολία του αλγορίθμου να διαχωρίσει περιοχές με μικρή μεταξύ τους απόσταση στον χρωματικό χώρο.

Συμπερασματικά, η επιλογή κατάλληλων τιμών για τα T1 και T2 είναι κρίσιμη για την επιτυχία της αναδρομικής μεθόδου, και η αποτελεσματικότητά της φαίνεται να εξαρτάται έντονα από τα χαρακτηριστικά της εικόνας εισόδου.